

# 1 Momentos y funciones generadoras

**Definición 1 (Media)** Sea  $X$  una variable aleatoria. La media de  $X$  o valor esperado de  $X$ , denotado por  $\mu_X$  o  $E[X]$  es definida por:

i)  $E[X] = \sum_{k=1}^{\infty} x_k p_k$  si  $X$  es una variable discreta con función de masa de probabilidad  $p_k = P([X=x_k])$  y  $\sum_{k=1}^{\infty} |x_k| p_k < \infty$ .

ii)  $E[X] = \int_{-\infty}^{\infty} x f_X(x) dx$  si  $X$  es una variable continua con función densidad de probabilidad  $f_X$  y  $\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty$ .

iii)  $E[X] = \int_0^{\infty} [1 - F_X(x)] dx - \int_{-\infty}^0 F_X(x) dx$  para una variable aleatoria arbitraria con  $\int_0^{\infty} [1 - F_X(x)] dx < \infty$  y  $\int_{-\infty}^0 F_X(x) dx < \infty$ .

Nota;  $E[X]$  es el centro de gravedad de la masa unitaria que es determinada por la función de densidad de  $X$ .

Así la media de  $X$  es una medida de donde los valores de la variable  $X$  se centran.

**Definición 1 (Media)** Sea  $(\Omega, S, P)$  un espacio probabilístico (espacio de medida).

a) Si  $A \in S$ , se llama integral  $I_A$  respecto a  $P$ , y se denota  $\int_{\Omega} I_A dP$ , el número real  $P(A)$ .

b) Sea  $X = \sum_{i=1}^n a_i I_{A_i}$  una función simple donde los  $A_i$  son sucesos dos a dos disjuntos y los  $a_i$  son números reales no negativos. Se define la integral de  $X$  respecto a  $P$ , y se denota por  $\int_{\Omega} X dP$ , como el número real  $\sum_{i=1}^n a_i P(A_i)$ .

c) Si  $X : \Omega \rightarrow \mathbb{R}$  es Borel-medible y no negativa, se define la integral de  $X$  respecto a  $P$  por  $\int_{\Omega} X dP = \sup \{ \int_{\Omega} s dP : s \text{ simple y } 0 \leq s \leq X \}$ .

d) Si  $X : \Omega \rightarrow \mathbb{R}$  es Borel-medible, se dice que  $X$  es  $P$ -integrable si las integrales de sus partes positivas y negativas son finitas; se dice que existe la integral de  $X$  respecto a  $P$  si al menos una de ellas es finita. En ambos casos se define  $\int_{\Omega} X dP = \int_{\Omega} X^+ dP - \int_{\Omega} X^- dP$ .

e) Si  $X$  es Borel-medible y  $A \in S$ , se denota  $\int_A X dP = \int_{\Omega} (X I_A) dP$ , si esta última integral existe.

Notación:  $\int X(\omega) dP(\omega)$ ,  $\int X(\omega) P(d\omega)$  y  $\int_{\Omega} X(\omega) dP(\omega)$  significa lo mismo que  $\int_{\Omega} X dP$ . Como  $P$  es una medida de probabilidad, entonces  $\int_{\Omega} X dP$  se suele denotar por la forma  $E_P(X)$  (o simplemente,  $E(X)$  o  $EX$ , si no hay confusión) y se llama esperanza o media de  $X$ .

Si  $X : \mathbb{R} \rightarrow \mathbb{R}$  es una variable aleatoria, su integral respecto a la medida de Lebesgue (si existe) se denota usualmente por  $\int X(x) dx$  o  $\int X$ , o  $\int_{\mathbb{R}} X(x) dx$  o también  $\int_{-\infty}^{\infty} X(x) dx$ .

**Teorema 1** Dado  $X(\omega) = I_A(\omega)$  para algún  $A \in S$ . Entonces  $E[X] = P(A)$ .

**Teorema 2** Si  $X$  es una variable aleatoria y  $h(X) = |X|$  se tiene:  $E[X]$  existe si y sólo si  $E[|X|]$  existe.

**Definición 2** Una  $X$  es una variable simétrica sobre un punto  $\alpha$  si  $P([X \geq \alpha + x]) = P([X \leq \alpha - x])$  para todo  $x \in \mathbb{R}$ .

Nota: Una función distribución  $F$  de  $X$  es simétrica (o una variable aleatoria  $X$  es simétrica) con  $\alpha$  como centro de simetría si

$F(\alpha - x) = 1 - F(\alpha + x) + P([X = \alpha + x])$  para todo  $x \in \mathbb{R}$ .

En particular, si  $X$  es una variable aleatoria continua y simétrica con centro en  $\alpha$  si y sólo si satisface  $f(\alpha - x) = f(\alpha + x)$  para todo  $x \in \mathbb{R}$ .

Si  $\alpha = 0$ ,  $X$  es simétrica (o  $F$  es simétrica).

**Teorema 3** Si  $X$  es una variable aleatoria simétrica con  $\alpha$  como centro de simetría y  $E[|X|] < \infty$ . Entonces  $E[X] = \alpha$ .

**Teorema 4** Si  $a$  y  $b$  son constantes y  $X$  es una variable aleatoria con  $E[|X|] < \infty$ . Entonces  $E[aX+b] < \infty$  y  $E[aX+b] = aE[X] + b$ .

Nota:  $E[X - \mu] = 0$ .

**Teorema 5** Si  $X$  es una variable aleatoria acotada, es decir,  $P([X] \leq M) = 1$ ,  $0 < M < \infty$ . Entonces  $E[X]$  existe.

**Teorema 6** Si  $X$  es una variable aleatoria con  $P([X \geq 0]) = 1$  y  $E[X]$  existe. Entonces  $E[X] \geq 0$ .

**Teorema 7** Sea  $X$  una variable aleatoria y  $g$  una función de Borel-medible sobre  $\mathbb{R}$ . Dado  $Y = g(X)$ . Si  $X$  es una variable aleatoria discreta, entonces

$$E[Y] = \sum_{j=1}^{\infty} g(x_j)P([X = x_j]) \quad (1)$$

en el sentido que si cualquiera lado de (1) existe, también existe el otro lado, y los dos son iguales. Si  $X$  es una función continua con función de densidad de probabilidad  $f$ , entonces:

$$E[Y] = \int_{-\infty}^{\infty} g(x)f(x)dx \quad (2)$$

en el sentido que si cualquier de las dos integrales convergen absolutamente en (2), también converge el otro lado, y los dos son iguales.

Nota: Sea  $X$  una variable aleatoria discreta. Entonces el teorema 7 dice que:

$$\sum_{j=1}^{\infty} g(x_j)P([X = x_j]) = \sum_{k=1}^{\infty} y_k P([Y = y_k])$$

en el sentido que si cualquiera de las dos series converge absolutamente, también converge la otra y las dos sumas son iguales. Si  $X$  es una variable continua con función densidad de probabilidad  $f$ . Sea  $h(y)$  la función densidad de probabilidad de  $Y=g(X)$ . Entonces según el teorema 7,

$$\int_{-\infty}^{\infty} g(x)f(x)dx = \int_{-\infty}^{\infty} yh(y)dy$$

dado que  $E[|g(X)|] < \infty$ .

Se puede definir para otros tipos de variables aleatorias.  $E[g(X)]$  es definida como la integral Stieltjes  $\int_{-\infty}^{\infty} g(x)dF_X(x)$  (dado que esta integral existe), donde  $F_X(x)$  es la función de distribución acumulada de  $X$ .

**Teorema 8** Sea  $X$  una variable aleatoria (discreta o continua), y  $g$  y  $h$  funciones de Borel-medible sobre  $\mathbb{R}$ . Entonces:

- i)  $E[cg(X)] = cE[g(X)]$  para  $c$  constante.
- ii)  $E[cg(X) + dh(x)] = cE[g(X)] + dE[h(X)]$  para  $c$  y  $d$  constantes.
- iii)  $E[g(X)] \leq E[h(X)]$  si  $g(x) \leq h(x)$  para todo  $x$ .

**Definición 3 (Varianza)** Sea  $X$  una variable aleatoria y sea  $\mu_X = E[X]$  existe. La varianza de  $X$ , denotado por  $\sigma_X^2$  o  $VAR[X]$ , es definido por:

- i)  $VAR[X] = \sum_{k=1}^{\infty} (x_k - \mu_X)^2 p_k$  si  $X$  es una variable discreta con función de masa de probabilidad  $p_k = P([X=x_k])$ .
- ii)  $VAR[X] = \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x)dx$  si  $X$  es una variable continua con función densidad de probabilidad  $f_X$ .
- iii)  $VAR[X] = \int_0^{\infty} 2x[1 - F_X(x) + F_X(-x)] dx - \mu_X^2$  para una variable aleatoria arbitraria.

Nota: La  $VAR[X]$  es una medida de la dispersión.

**Definición 4 (Desviación estándar)** Si  $X$  es una variable aleatoria, la desviación estándar de  $X$ , denotada por  $\sigma_X$  es definida como  $+\sqrt{VAR[X]}$ .

**Teorema 9** Si  $X$  es una variable aleatoria y  $E[X^2]$  existe, entonces  $VAR[X] = E[X^2] - (E[X])^2$ .

**Definición 5** Una variable aleatoria  $X$  es degenerada en el punto  $k$  si

$$P([X=x]) = \begin{cases} 1 & , \quad x = k \\ 0 & , \quad \text{cualquier otro lugar} \end{cases}$$

**Teorema 10** Si  $X$  es una variable aleatoria discreta y  $E[X^2]$  existe. Entonces  $VAR(X)=0$  si y sólo si  $X$  es degenerada.

**Teorema 11** Sea  $X$  una variable aleatoria y  $E[X^2]$  existe. Entonces  $\text{VAR}(X) < E[(X-c)^2]$  para cualquier  $c \neq E[X]$ .

**Teorema 12** Sea  $X$  una variable aleatoria y  $E[X^2]$  existe. Entonces,  $\text{VAR}[aX+b] = a^2 \text{VAR}[X]$  para cualquier  $a$  y  $b$  constantes.

**Definición 6** Una variable aleatoria  $Z$  es estandarizada si  $E[Z]=0$  y  $\text{VAR}[Z]=1$ .

Nota: Sea una variable aleatoria  $X$  y  $E[|X|^2] < \infty$ . Se define  $Z = \frac{X-E[X]}{\sqrt{\text{VAR}[X]}} = \frac{X-\mu}{\sigma}$ .

Se tiene que  $E[Z]=0$  y  $\text{VAR}[Z]=1$ .

**Definición 7 (Momentos)** Si  $X$  es una variable aleatoria, el  $r$ -ésimo momento de  $X$  (sobre el origen) o el momento de orden  $r$ , denotado por  $m_r$ , es definido como  $m_r = E[X^r]$  si el valor esperado existe.

**Definición 8 (Momentos centrales)** Si  $X$  es una variable aleatoria, el  $r$ -ésimo momento central de  $X$  sobre  $a$  es definido como  $E[(X-a)^r]$ . Si  $a=\mu$ , se tiene el  $r$ -ésimo momento central sobre  $\mu$  (o la media), denotado por  $\mu_r$ , el cual es  $\mu_r = E[(X-\mu)^r]$ .

Nota: Si se conocen  $m_1, m_2, \dots, m_k$ , se pueden calcular  $\mu_1, \mu_2, \dots, \mu_k$ , y viceversa.

Se tiene  $\mu_k = E[(X-\mu)^k] = m_k - \binom{k}{1} \mu m_{k-1} + \binom{k}{2} \mu^2 m_{k-2} - \dots + (-1)^k \mu^k$  y

$m_k = E[(X-\mu + \mu)^k] = \mu_k + \binom{k}{1} \mu \mu_{k-1} + \binom{k}{2} \mu^2 \mu_{k-2} + \dots + \mu^k$

**Definición 9 (Momentos factoriales)** Si  $X$  es una variable aleatoria, el  $r$ -ésimo momento factorial de  $X$  es definido como ( $r$  es un entero positivo):  $E[X(X-1)\dots(X-r+1)]$ .

Nota: Para algunas variables aleatorias de valores enteros discretos cuya función de masa de probabilidad contiene factoriales o coeficientes binomiales, puede ser más conveniente calcular momentos factoriales.

**Definición 10 (Cuantil)** Un número  $x$  satisfaciendo  $P([X \leq x]) \geq p$ ,  $P([X \geq x]) \geq 1 - p$ .  $0 < p < 1$ , es llamado un cuantil de orden  $p$  (o  $100p$ -ésimo percentil) para la variable aleatoria  $X$  (o para la función distribución  $F$  de  $X$ ) y se denota por  $\xi_p(X)$ .

Nota: Si  $x$  es un cuantil de orden  $p$  para la variable aleatoria  $X$  con función distribución  $F$ , entonces

$p \leq F(x) \leq p + P([X=x])$ .

Si  $X$  es una variable aleatoria continua, un cuantil de orden  $p$  es una solución de la ecuación  $F(x)=p$  ya que  $P([X=x])=0$ .

Si  $F$  es estrictamente creciente, la solución es única. De otra forma, pueden haber muchas (inclusive incontables) soluciones de  $F(x)=p$ , cada uno de los cuales es llamado un cuantil de orden  $p$ .

**Definición 11 (Mediana)** Sea una variable aleatoria con función distribución  $F$ . Un número que satisface  $\frac{1}{2} \leq F(x) \leq \frac{1}{2} + P([X=x])$  o equivalentemente  $P([X \leq x]) \geq \frac{1}{2}$  y  $P([X \geq x]) \geq \frac{1}{2}$  es llamado la mediana de  $X$  (o  $F$ ).

**Teorema 13** Si el momento de orden  $t$  existe para una variable aleatoria  $X$ , momentos de orden  $0 < s < t$  existen.

**Teorema 14** Sea  $X$  una variable aleatoria no negativa con función distribución  $F$ . Entonces,  $E[X] = \int_0^\infty (1-F(x))dx$ , en el sentido que si cualquier lado existe, también el otro existe y los dos son iguales.

**Definición 12** Sea  $X$  una variable aleatoria definida sobre  $(\Omega, S, P)$ . La función

$$M(s) = E[e^{sX}] \quad (3)$$

es conocida como la función generadora de momentos de la variable aleatoria  $X$  si el valor esperado del lado derecho de (3) existe en alguna vecindad del origen.

Nota:  $M_X$  denota la función generadora de momentos de la variable aleatoria  $X$ .

**Teorema 15** Sean  $X$  y  $Y$  dos variables aleatorias con funciones de densidad  $f_X$  y  $f_Y$  respectivamente.

- a) Si  $M_X(s)$  y  $M_Y(s)$  existen y son iguales para todo  $s$  en el intervalo  $-h < s < h$  para algún  $h > 0$ . Entonces, las dos funciones de distribución  $F_X$  y  $F_Y$  son iguales.
- b) Si  $M_X(s)$  existe para todo  $s$  en el intervalo  $-h < s < h$  para algún  $h > 0$  y las dos funciones de distribución  $F_X$  y  $F_Y$  son iguales, entonces  $M_X(s)$  y  $M_Y(s)$  son iguales para todo  $s$  en el intervalo  $-h < s < h$  para algún  $h > 0$ .

**Teorema 16** Si la función generadora de momentos  $M(s)$  de una variable aleatoria  $X$  existe para  $s$  en  $(-s_0, s_0)$  con  $s_0 > 0$ , entonces las derivadas de todos los órdenes existen en  $s=0$  y pueden ser evaluadas bajo el signo de la integral, es decir,

$$M^{(k)}(s) |_{s=0} = E[X^k] \text{ para } k=1,2,\dots$$

$$\text{Nota: } M(s) = E[e^{sX}] = E\left[\sum_{i=0}^{\infty} \frac{1}{i!} (sX)^i\right] = \sum_{i=0}^{\infty} \frac{1}{i!} m_i s^i$$

**Teorema 17** Sea  $h(X)$  una función no negativa Borel medible de una variable aleatoria  $X$ . Si  $E[h(X)]$  existe, entonces para cualquier  $\epsilon > 0$ ,  $P([h(X) \geq \epsilon]) \leq \frac{E[h(X)]}{\epsilon}$ .

**Teorema 18** Sea  $X$  una variable aleatoria, dado  $h(X) = |X|^r$  y  $\epsilon = K^r$ , donde  $r > 0$  y  $K > 0$ . Entonces  $P(|X| \geq K) \leq \frac{E[|X|^r]}{K^r}$ , la cual es la desigualdad de Markov.

En particular si  $h(X)=(X-\mu)^2$  y  $\epsilon = K^2\sigma^2$ , se tiene la desigualdad de Chebychev-Bienayme:

$$P(|X - \mu| \geq K\sigma) \leq \frac{1}{K^2}, \text{ donde } E[X] = \mu \text{ y } \text{VAR}(X) = \sigma^2.$$

**Definición 13 (Función Convexa)** Una función  $g : \mathbb{R} \rightarrow \mathbb{R}$  es convexa si para cualquier  $x, y \in \mathbb{R}$  y cualquier  $t \in [0, 1]$ ,  $g(tx + (1-t)y) \leq tg(x) + (1-t)g(y)$ .

Nota: Geométricamente significa que en cada intervalo  $[x, y]$  la gráfica de  $g$  queda por debajo del segmento que va de  $(x, g(x))$  a  $(y, g(y))$ .

**Teorema 19 (Desigualdad de Jensen)** Sea  $X$  una variable aleatoria con media  $E[X]$ , y sea  $g$  una función convexa y continua. Entonces  $E[g(X)] \geq g(E[X])$ .

## 2 Bibliografía

- Rohatgi, V. y Saleh, A. (2001), An Introduction to Probability and Statistics. John Wiley and Sons, Inc.